

# Дискретная оптимизация

## весна 2013

Александр Дайняк


<http://www.dainiak.com>

# Метаэвристики

- Метод ветвлений и ограничений (ветвей и границ, branch and bound)
- Имитация отжига
- Алгоритмы «по мотивам биологических явлений»:
  - Генетические алгоритмы (genetic algorithms)
  - Алгоритмы «муравьиных колоний» (ant colony algorithms)


# Метод ветвей и границ

- Минимизируем функцию  $f$  на множестве  $S$
- Просматривать всё множество  $S$  накладно
- Разбиваем множество  $S$  на части, ищем в каждой части верхнюю и нижнюю оценку для  $f_{min}$  на подобласти:




# Метод ветвей и границ

- Если оказывается, что  $\exists i, j : f_i^{low} \leq f_j^{up}$ , то больше не рассматриваем  $j$ -ю область



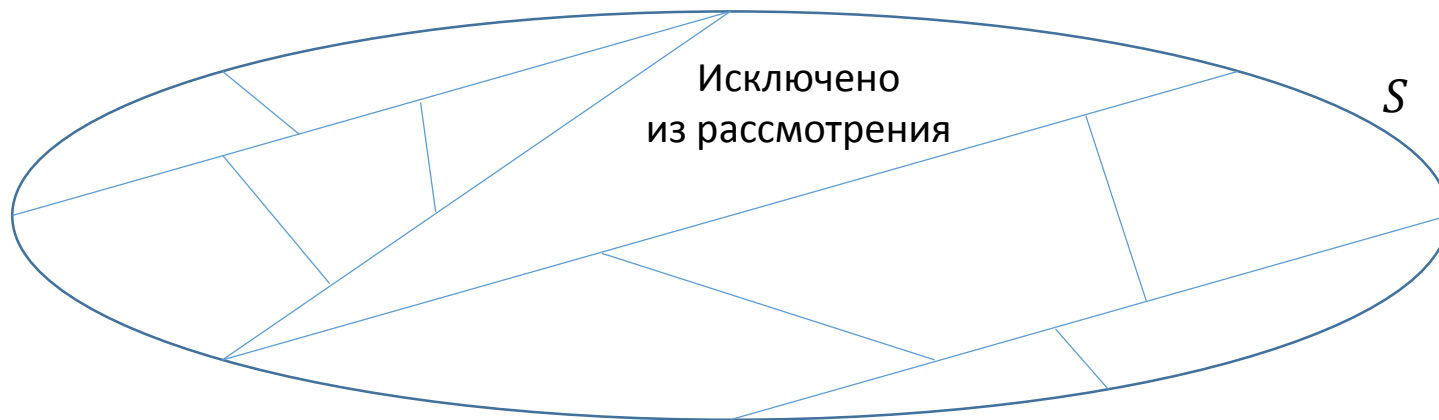
# Метод ветвей и границ

- Если оказывается, что  $\exists i, j : f_i^{low} \leq f_j^{up}$ , то больше не рассматриваем  $j$ -ю область



# Метод ветвей и границ

- Рекурсивно производим ту же процедуру на подобластях:



# Метод ветвей и границ

- Метод ветвей и границ эффективен, если
  - Хорошие оценки минимума функции  $f$  на подобластях легко вычислить (например, локальным поиском или другими эвристиками)
  - Можно эффективно производить разбиение множества  $S$  на области примерно равного размера (в этом случае метод можно эффективно распараллелить)

# Пример применения метода в задаче коммивояжёра

- $S$  — множество всех ГЦ в графе  $G$
- Разбиение множества  $S$  на подмножества:
  - $S = S_e \sqcup S_{\bar{e}}$ , где  $S_e = \{h \in S \mid e \in H\}$
  - Фиксируем  $E' \subset E(G)$  и раскладываем  $S = \sqcup_{A \in E'} S_A$ , где  $S_A = \{h \in S \mid A \subseteq H\}$
- Нижние оценки веса минимального ГЦ:
  - Вес минимального остовного дерева
  - ...
- Верхняя оценка веса минимального ГЦ — вес любого ГЦ.




# Имитация отжига

Общая идея:

- Локальный поиск очень прост идейно, но может «застревать» в локальных экстремумах.
- Чтобы выбираться из локальных экстремумов, нужно иногда далеко от них отдаляться.
- Постепенно уменьшаем «рискованность» — дальность прыжка, на которую мы выскакиваем из локального оптимума.

Физическая идея: по мере остывания вещества перемещения атомов в кристаллической решётке всё менее амплитудны.

# Имитация отжига



# Имитация отжига: псевдокод (максимизируем функцию $f$ )

// В коде ниже  $P(\dots)$  – функция в  $[0,1]$ , `random` – генератор случайных чисел из  $[0,1]$ ,  
// `temperature` – убывающая функция, `neighbour` – рандомизированная функция выбора «соседа».

```
s ← s0; fs ← f(s)
sbest ← s; fbest ← f(s)
k ← 0
while k < kmax and fs < ftolerable
    T ← temperature(k/kmax)
    snew ← neighbour(s, T)
    fnew ← f(snew)
    if P(fs, fnew, T) > random() then
        s ← snew; fs ← fnew
        if fs > fbest then
            sbest ← snew; fbest ← fs
    k ← k + 1
return sbest
```

```
// Начальное состояние

// Счётчик числа шагов
// Пока есть время и простор для улучшения...
// вычисляем, какая сейчас «температура»,
// выбираем точку-кандидата на перемещение,
// вычисляем, насколько хороша новая точка,
// определяем, перемещаться ли в неё.
// Перемещаемся
// Если удалось улучшить результат,
// то сохраняем об этом информацию
```

# Генетические (эволюционные) алгоритмы

- Идея — естественный отбор в ходе эволюции:
  - Имеется популяция особей, обитающих во враждебной среде
  - Особи скрещиваются, передавая потомкам часть своих генов
  - Наиболее приспособленные потомки выживают

# Генетические (эволюционные) алгоритмы

- Минимизируем функцию  $f$  на множестве  $S$
- Формализация генетического алгоритма:
  - Задаёмся функциями скрещивания  $C$  и мутации  $M$ 
$$C: S \times S \rightarrow S, \quad M: S \rightarrow S$$
  - 1. Выбираем «начальную популяцию»  $A \subseteq S$ ,  $|A| = m$
  - 2. Строим множество «потомков»:  $D = \{C(s', s'') \mid s', s'' \in A\}$  и множество «мутантов»  $J = \{M(s) \mid s \in A\}$
  - 3. Сортируем множество  $A \cup D \cup J$  по возрастанию значений функции  $f$  и берём первые  $m$  элементов. Они составляют новую популяцию  $A$ .  
Переходим к шагу 2.

# Генетические (эволюционные) алгоритмы

$$A_{\text{new}} = \text{best}_m(A_{\text{old}} \cup \{C(s', s'') \mid s', s'' \in A_{\text{old}}\} \cup \{M(s) \mid s \in A_{\text{old}}\})$$

- Когда можно останавливаться:

- Значение функции  $f$  достаточно мало:

$$\min_{s \in A_{\text{new}}} f(s) < \gamma$$

- Новая популяция ненамного лучше старой:

$$\min_{s \in A_{\text{new}}} f(s) \geq 0.99 \cdot \min_{s \in A_{\text{old}}} f(s)$$



# Генетические (эволюционные) алгоритмы

$$A_{\text{new}} = \\ = \text{best}_m(A_{\text{old}} \cup \{C(s', s'') \mid s', s'' \in A_{\text{old}}\} \cup \{M(s) \mid s \in A_{\text{old}}\})$$




- Выбор функции мутации:
  - Берём окрестностную функцию  $N$  из локального поиска и полагаем  $M(s) = \text{random}(N(s))$  или  $M(s) = \text{best}(N(s))$
- Выбор функции скрещивания:
  - Если  $S \subset \mathbf{R}^n$ , то можно взять  $C(s', s'') = \frac{1}{2}(s' + s'')$  или  $C((s'_1, \dots, s'_n), (s''_1, \dots, s''_n)) = (s'_1, \dots, s'_i, s''_{i+1}, \dots, s''_n)$
  - Обычно диктуется спецификой задачи: что такое «хорошие гены» особи
  - Функция скрещивания может быть от  $\geq 3$  переменных

# Генетические алгоритмы

- Пример применения ГА в задаче поиска кратчайшего пути:
  - Мутация:



- Скрещивание:





# Генетические (эволюционные) алгоритмы

- Пример применения ГА в задаче коммивояжёра:
  - Функцию мутации строим по  $k$ -окрестности (удаление/добавление  $k$  рёбер)
  - Скрещивание: часть графа обходим по первому ГЦ, а оставшиеся вершины обходим в том порядке, в каком они лежат на втором ГЦ

# Генетические (эволюционные) алгоритмы

- Плюсы:
  - Простота и естественность подхода
  - Наличие большого числа управляемых параметров
  - Эффективность при удачной реализации
  - Возможность распараллеливания вычислений значений функций скрещивания и мутации
- Минусы:
  - Сложность формального анализа (как следствие, отсутствие гарантии результата)
  - Необходимость подбора параметров

# Алгоритмы муравьиных колоний

- Общая идея:


Колонии насекомых в природе при поиске пищи ориентируются по запахам.

Насекомое, найдя «клад», возвращается в колонию, оставляя по пути запаховую метку.

Отправляющиеся из колонии собратья с большей вероятностью идут туда, где «запах успеха» сильнее.


# Алгоритмы муравьиных колоний

- Наилучшим образом алгоритмы м.к. подходят для задач, которые могут быть сведены к оптимальному обходу графов:




# Алгоритмы муравьиных колоний

- Наилучшим образом алгоритмы м.к. подходят для задач, которые могут быть сведены к оптимальному обходу графов:




# Алгоритмы муравьиных колоний

- Наилучшим образом алгоритмы м.к. подходят для задач, которые могут быть сведены к оптимальному обходу графов:




# Алгоритмы муравьиных колоний

- Наилучшим образом алгоритмы м.к. подходят для задач, которые могут быть сведены к оптимальному обходу графов:



# Алгоритмы муравьиных колоний


- Наилучшим образом алгоритмы м.к. подходят для задач, которые могут быть сведены к оптимальному обходу графов:






# Алгоритмы муравьиных колоний

- «Муравьиный» алгоритм поиска кратчайшего пути в графе:
  - Дан граф  $G$  с весами на рёбрах, и пара вершин  $u, v \in V(G)$
  - На каждом ребре  $e$  графа храним «запах»  $\text{pher}(e) \geq 0$
  - Из вершины  $u$  по графу отправляется агент, который, попав в очередную вершину, идёт в её соседа с вероятностью, пропорциональной  $\text{pher}(e)$  и обратно пропорциональной  $w(e)$



# Алгоритмы муравьиных колоний

- «Муравьиный» алгоритм поиска кратчайшего пути в графе:
  - Дан граф  $G$  с весами на рёбрах, и пара вершин  $u, v \in V(G)$
  - На каждом ребре  $e$  графа храним «запах»  $\text{pher}(e) \geq 0$
  - Дойдя до  $v$ , агент увеличивает запах на рёбрах пройденного пути на величину, обратно пропорциональную длине пути



# Алгоритмы муравьиных колоний

- Плюсы:
  - Одновременно можно запускать несколько агентов, что позволяет распараллелить поиск решения
  - Поведения агентов можно изменять в широких пределах
- Минусы:
  - Агенты обращаются к общей памяти (массив «запахов»)
  - Сложность формального анализа (как следствие, отсутствие гарантии результата)
  - Необходимость подбора параметров

# Резюме

- Метод ветвей и границ может использоваться для получения доказуемо оптимального решения
- Имитация отжига подходит, когда нужно «выпрыгивать» из локальных оптимумов
- Генетические и муравьиные алгоритмы сложны для формального анализа и не гарантируют нахождения оптимального решения, однако универсальны, идейно просты и могут дать начальное приближение для решения прикладной задачи
- При разработке современных эвристик важно смотреть на возможности распараллеливания